



به نام خدا

سیستم عامل - بهار ۱۴۰۴

استاد: دکتر مهدی کارگهی

پروژه دوم: برنامه‌های چندپردازه‌ای^۱ و ارتباط میان‌پردازه‌ای^۲

طراحان: بهراد علمی - محمد امانلو



اهداف

در این پروژه با برنامه‌های چندپردازه‌ای و نحوه برقراری ارتباط میان آن‌ها از طریق لوله^۳ خواهید پرداخت. برای آشنایی هرچه بهتر با این موضوع، نسخه ساده شده‌ای از کاربرد آن در سیستم‌های توزیع شده^۴ و خدمات مبتنی بر ابر^۵ را مشاهده و پیاده‌سازی خواهید کرد.

مقدمه

یکی از راه‌حلهایی که امروزه برای به‌دست آوردن اطلاعات هدف از داده‌های بزرگ^۶ استفاده می‌شود، تعریف خط لوله‌هایی^۷ است که استخراج و انجام عملیات روی داده‌ها را به صورت همزمان میسر می‌کند. برای مثالی از این الگو، می‌توان به مدل [Apache Beam](#) اشاره کرد که خود در سرویس‌هایی مانند [Apache Spark](#) و [Google Cloud Dataflow](#) نیز مورد استفاده قرار گرفته است. به منظور بهره‌برداری از این الگو، در این پروژه خط لوله‌هایی را تعریف خواهیم کرد که از سه قسمت عمده زیر تشکیل شده‌اند:

^۱ Multiprocess Programs

^۲ Interprocess Communication (IPC)

^۳ Pipe


^۴ Distributed Systems

^۵ Cloud-Based Services

^۶ Big Data

^۷ Pipeline

1. ETL⁸: در این قسمت، ابتدا داده‌ها از منابع و پایگاه داده‌های موجود استخراج خواهند شد. سپس با فرض صحیح بودن ساختار داده، می‌توان فیلترها و یا تغییرات مورد نظر را اعمال کرد. در نهایت خروجی این مرحله تجمیع شده و به مراحل بعدی انتقال خواهد یافت.
2. محاسبات شبکه‌وار⁹: در این مرحله، محاسبات مدنظر روی داده‌های ورودی، توسط گره‌های¹⁰ محاسبه‌گر انجام شده و به خروجی محاسبات در مرحله بعد انتقال خواهد یافت.
3. خروجی نهایی: در انتها داده‌های نهایی در مقصد مورد نظر نوشته و یا منتقل خواهند شد.



شکل ۱. شمایی از روند تبیین شده.


شرح پروژه

در این پروژه به پیاده‌سازی فرایند ساده شده‌ای از یک مکانیزم رتبه‌بندی محبوبیت برای بازی‌هایی که توسط شرکت Steam ارائه می‌شود خواهید پرداخت. معیار رتبه‌بندی بر اساس نظرات کاربران، امتیاز کاربران و دیگر پارامترهایی است که در ادامه توضیح داده خواهند شد. شکل ۲ بیان‌گر ساختار چنین فرایندی است.

⁸ Extract, Transform, Load

⁹ Grid Computing

¹⁰ Nodes



شکل ۲. ساختار گره‌ها و خط لوله تعریف شده برای این پروژه.

فایل‌های ورودی

در ابتدا اطلاعات کاربران از پایگاه داده‌های Steam که به شکل فایل‌های csv در اختیاران قرار گرفته است را استخراج می‌کنید (تنها کافی است در برنامه خود از این فایل‌ها بخوانید). سپس مرحله‌ای که در ادامه توضیح داده شده‌اند را پیاده‌سازی می‌کنید تا فرایند سیستم رتبه‌بندی را کامل کنید.

این فایل‌ها شامل ستون‌های زیر می‌باشند:

1. **Title (عنوان بازی):** نام بازی در فروشگاه Steam.
2. **Original Price (قیمت اصلی):** قیمت اولیه‌ای که سازندگان یا ناشران بازی برای آن تعیین کرده‌اند (قبل از تخفیف).
3. **Discounted Price (قیمت پس از تخفیف):** قیمتی که بازی در حال حاضر (در صورت وجود تخفیف) به فروش می‌رسد.
4. **Link (لینک):** آدرس صفحه بازی در فروشگاه Steam.
5. **Game Description (توضیحات بازی):** توضیح مختصری از داستان، گیم‌پلی یا سایر ویژگی‌های اصلی بازی (متن معرفی در صفحه استیم).

6. **Recent Reviews Summary (خلاصه نظرات اخیر):** امتیاز کلی یا بازخورد کاربران در دوره زمانی اخیر (مثلاً یک ماه گذشته) به صورت توصیفی (مثلاً Positive, Very Positive).
7. **All Reviews Summary (خلاصه تمام نظرات):** خلاصه کلی امتیاز یا بازخورد کاربران از ابتدای عرضه بازی تا کنون.
8. **Recent Reviews Number (تعداد نظرات اخیر):** اطلاعات خلاصه از تعداد نظرات و بررسی‌هایی که در دوره زمانی اخیر توسط کاربران ثبت شده است.
9. **All Reviews Number (تعداد کل نظرات):** تعداد کل نظرات و بررسی‌های ثبت‌شده از زمان عرضه تا کنون.
10. **Developer (توسعه‌دهنده):** نام شرکت یا گروه سازنده بازی.
11. **Publisher (ناشر):** نام شرکت یا شخصی که بازی را منتشر کرده و مسئولیت عرضه آن را برعهده دارد.
12. **Popular Tags (تگ‌های محبوب):** کلمات کلیدی متداولی که کاربران و خود استیم برای توصیف ژانر، سبک یا ویژگی‌های بازی به کار می‌برند.
13. **Game Features (ویژگی‌های بازی):** امکانات و حالت‌های مختلف بازی نظیر تک‌نفره، چندنفره، رقابتی، همکاری آنلاین، پشتیبانی از کنترلر و غیره.
14. **Minimum Requirements (حداقل سیستم موردنیاز):** اطلاعات حداقلی از سخت‌افزار و سیستم‌عاملی که برای اجرای بازی لازم است (بر اساس اطلاعات ارائه‌شده توسط سازنده).

استخراج و تبدیل

این مرحله حاوی پردازش‌هایی¹¹ است که عمل خواندن از فایل‌های ورودی متناظر خود را انجام داده¹²، فیلترهای مورد نظر را اعمال می‌کنند و سپس داده‌ها را به مرحله بعد ارسال می‌کنند.

در این مرحله اقدامات زیر انجام خواهند شد:

- حذف ستون‌های 4، 5، 10، 11، 12، 13 و 14 (قسمت قبل را مشاهده کنید).
- حذف علامت \$ از قیمت‌ها (Original و Discounted) تا تنها رشته عددی باقی بماند.

¹¹ Processes

¹² می‌توانید فرض کنید به ازای هر فایل، یک پردازش عمل خواندن از آن را انجام می‌دهد و کافی است به تعداد فایل‌های مورد نیاز پردازش ایجاد کنید.

- تبدیل ستون All Reviews Number و Recent Reviews Number به تعداد کاربرانی که بررسی ثبت کرده‌اند.
- تبدیل ستون Discounted Price به درصد تخفیف (در صورتی که درصد تخفیف صفر بود آن را یک در نظر بگیرید).
- تبدیل ستون‌های All Reviews Summary و Recent Reviews Summary به مقادیر عددی به ترتیب زیر:

Summary	Corresponding number
Overwhelmingly Positive	7
Very Positive	6
Positive	5
Mostly Positive	4
Mixed	3
Mostly Negative	2
Overwhelmingly Negative	1

- ارسال اطلاعات استخراج شده به مرحله بعد.

نکته: در صورت نیاز می‌توانید در این مرحله، بدون تغییر مقادیر داده‌ها، آن‌ها را به فرمت دلخواه خود تبدیل و در داده ساختارهای دلخواه خود ذخیره کنید تا انجام عملیات و کار کردن با داده‌ها برایتان ساده‌تر شود.

بارگیری

پس از انجام مرحله قبل و استخراج داده‌های فیلتر شده، تمامی داده‌ها در گره بارگیری تجمیع می‌شوند تا توسط این گره به مرحله بعد توزیع شوند. در این مرحله برخی از پیش‌پردازش‌های ضروری دیگر که نیاز به تجمیع تمامی داده‌ها دارند انجام می‌شوند.

در این مرحله اقدامات زیر انجام خواهند شد:

- استخراج کمینه و بیشینه‌های تمامی ستون‌های باقیمانده.
- ارسال کمینه و بیشینه کلی هر ستون به مرحله بعد (به هر پردازش در محاسبات شبکه‌وار).
- توزیع داده‌های ورودی از مرحله قبل به مرحله بعد.

می‌توانید اطلاعات کمینه و بیشینه و داده‌های ورودی از مرحله قبل را به صورت یکجا یا در چند مرحله، به مرحله بعد منتقل کنید.

برای توزیع داده‌ها میان گره‌های مرحله بعد (گره‌های محاسبه‌گر) می‌توانید از ترتیب دلخواه خود استفاده کنید. اما دقت داشته باشید تا توزیع به نحوی صورت گیرد تا به تمامی گره‌ها میزانی داده برای پردازش برسد.

محاسبات شبکه‌وار

تا این مرحله شما تمامی ستون‌های لازم را استخراج کرده و دیگر اطلاعات مورد نیاز را در اختیار دارید و آماده محاسبه یک شاخص برای به‌دست آوردن محبوبیت می‌باشید.

برای محاسبه شاخص، از روش ¹³MCDA بهره خواهیم برد.

ابتدا با توجه به اطلاعات دریافت شده از مرحله قبل به روش Min-Max Scaling داده‌های متناظر هر ستون را اسکیل کنید. برای این کار می‌توانید از فرمول زیر استفاده کنید:

¹³ Multi-Criteria Decision Analysis

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}} + 1$$

در این فرمول از هر داده کمینه آن ستون را کم کرده و سپس بر بازه اعداد موجود در ستون تقسیم کرده و در نهایت حاصل را با عدد ۱ جمع کنید. دقت داشته باشید که اعداد بیشینه و کمینه را از مرحله قبل (بارگیری) دریافت کرده‌اید.

سپس از فرمول زیر برای محاسبه شاخص بهره خواهیم برد که در آن هر چه امتیاز بالاتر باشد، بهتر است:

$$Criterion = \frac{10 \times X_{Discount} \times X_{RecentSummary} \times X_{AllSummary} \times X_{RecentNum} \times X_{AllNum}}{X_{OriginalPrice}}$$

در این فرمول عدد ۱۰ را در حاصلضرب اعداد تمامی ستون‌های عددی ضرب کرده و بر قیمت اولیه تقسیم کنید.

حال کافی است تا عنوان بازی و شاخصی که محاسبه کردید را برای مرحله بعد ارسال کنید.

خروجی

پس از گرفتن امتیاز محاسبه شده برای هر بازی و نام آن بازی از مرحله قبل، بازی‌ها را رتبه‌بندی کرده و به صورت مرتب‌شده در فایلی با نام **GameRanking.csv** ذخیره کنید.

ساختار پدازه‌ها

پس از آشنایی با مسئولیتی که بر عهده هر کدام از انواع گره‌ها و پدازه‌ها قرار گرفته است، در این قسمت با ساختار ایجاد پدازه‌ها آشنا خواهید شد.

همانطور که در درس نیز فرا گرفته‌اید پس از ایجاد پدازه‌ها دو امکان از منظر فضای آدرس‌دهی^{۱۴} پدازه فرزند وجود خواهد داشت:

¹⁴ Address Space

1. پردازۀ فرزند نسخه یکسانی از پردازۀ والد را اجرا می‌کند و فضای آدرس‌دهی آن تغییر نمی‌کند.
2. پردازۀ فرزند برنامه جدیدی را اجرا خواهد کرد (به عنوان مثال بعد از fork عمل exec انجام خواهد شد) و فضای آدرس‌دهی آن تغییر می‌کند.

نکته: در نظر داشته باشید برای ایجاد پردازۀها از نوع دوم نیازمند برنامه‌ای از قبل کامپایل شده‌ای هستید تا در پردازۀ فرزند مورد اجرا قرار گیرد.

ساختار پردازۀها را از این منظر بررسی خواهیم کرد:

- استخراج و تبدیل: تعداد پردازۀهای استخراج با تعداد پردازۀهای تبدیل یکسان و برابر با تعداد فایل‌های ورودی می‌باشد. این دو نوع پردازۀ در یک برنامه خواهند بود.
- بارگیری: تنها یک پردازۀ و در برنامه‌ای مجزا خواهد بود.
- محاسبات شبکه‌وار: تعداد پردازۀهای این مرحله توسط آرگومان خط فرمان¹⁵ تعیین خواهد شد و خود برنامه به صورت مجزا خواهد بود.
- تعداد پردازۀهای محاسبه‌گر می‌تواند در سرعت پردازش تغییراتی ایجاد کند. اما توجه داشته باشید که تعداد پردازۀها در نتیجه نهایی تاثیری نخواهد داشت.
- خروجی: تنها یک پردازۀ و در فضای آدرس‌دهی مجزا خواهد بود.

بار تراز¹⁶ (امتیازی)

در مرحله‌ای که داده‌ها از گره بارگیری برای گره‌های محاسبه‌گر فرستاده می‌شوند، از ترتیب دلخواه خود برای توزیع داده‌ها استفاده کردید. در این قسمت قابلیت‌ی را پیاده‌سازی کنید که داده‌ها به ترتیب به گره‌های محاسبه‌گری ارسال شوند که دارای کمترین میزان استفاده از CPU سیستم شما هستند.

نکات پیاده‌سازی

- برای ایجاد پردازۀهای جدید از فراخوانی سیستمی fork و برای جایگزینی یک برنامه جدید از exec و یا انواع مختلف آن (execl, execv, ...) استفاده کنید.

¹⁵ Command Line Argument

¹⁶ Load Balancing

- دقت داشته باشید که تنها راه ارتباطی میان پردازنده‌های مختلف لوله‌ها¹⁷ هستند و استفاده از دیگر راه‌های ارتباطی قابل قبول نمی‌باشد.
- در هنگام انتقال اطلاعات میان پردازنده‌ها به کمک لوله‌ها دقت داشته باشید که چند پردازنده به صورت همزمان در یک لوله ننویسند تا ترتیب داده‌ها درون لوله به هم نریزد.
- پس از استفاده از لوله‌ها، طرفی از لوله که استفاده نمی‌شود را ببندید (یا تنها دسترسی‌هایی که لازم است را بدهید). برای این کار از فراخوانی سیستمی close استفاده کنید.
- برای ساخت Named Pipe می‌توانید از فراخوانی سیستمی mkfifo و برای ساخت Unnamed/Ordinary Pipe می‌توانید از فراخوانی سیستمی pipe استفاده کنید.
- برای خواندن یا نوشتن اطلاعات از Named Pipe ای که پیش‌تر ساخته شده می‌توانید از فراخوانی سیستمی open استفاده کنید. دقت داشته باشید، در این حالت برای انتقال اطلاعات میان دو پردازنده، باید یک طرف به عنوان خواننده و یک طرف به عنوان نویسنده، Named Pipe را باز کرده باشند تا انتقال اطلاعات شروع شود.
- در انتخاب Named Pipe و Unnamed/Ordinary Pipe دقت کنید و به‌جز مواردی که لازم است از Named Pipe استفاده نکنید. این مورد قسمتی از ارزشیابی شما را به همراه خواهد داشت.
- به منظور نحوه ایجاد پردازنده‌ها برای تشکیل ساختار پردازنده‌ها، می‌توانید از فرض منطقی و دلخواه خود استفاده کنید.
- توجه داشته باشید که در پردازنده‌هایی که ایجاد می‌کنید، پردازنده‌ای در حالت Zombie باقی نمانده و از فراخوانی سیستمی wait (و یا انواع آن) برای اتمام صحیح پردازنده استفاده کنید.
- پروژه شما می‌بایست با استفاده از اجرای تنها یک برنامه از سمت کاربر، اجرایی شود.

¹⁷ Pipes

نکات و نحوه تحویل

- کدهای شما می‌بایست به زبان C++/C بوده و با استفاده از Makefile و کامپایلر g++ قابل کامپایل و اجرا باشند.
- پروژه شما می‌بایست در سیستم عامل Linux و در زمان معقول قابل اجرا باشد.
- تمامی کدها و فایل‌های خود را به صورت zip شده و به فرمت **OS-CA2-<SID>.zip** در صفحه درس بارگذاری کنید.
- در صورت داشتن سوال می‌توانید از طریق فروم یا گروه درس و یا شرکت در جلسات رفع اشکال سوالات خود را مطرح کنید.
- تمامی مواردی که در فروم یا گروه درس و یا جلسات رفع اشکال به آن اشاره می‌شود جزئی از این تمرین خواهند بود.
- این تمرین صرفاً برای یادگیری شما طراحی شده است. در صورت محرز شدن هرگونه تخلف، مطابق قوانین درس با آن برخورد خواهد شد.

موفق باشید!